

Analisis dan Implementasi Klasifikasi Data Menggunakan Perceptron dan ADALINE

Tugas Besar 1 — Jaringan Syaraf Tiruan (IT6053)

Hendrikus Lanang Ona / 71241114
Harison Abraham Pribadi / 71241151
Jochelino Felix Kurniawan / 71241156

Fakultas Teknologi Informasi
Universitas Kristen Duta Wacana
2026

1. Masalah dan Tujuan

Masalah. Diagnosis diabetes umumnya membutuhkan pemeriksaan laboratorium lanjutan, padahal data pemeriksaan dasar pasien (kadar glukosa, tekanan darah, BMI, usia, dan sejenisnya) sudah rutin dikumpulkan pada kunjungan klinis. Pertanyaan yang ingin dijawab: **dapatkah data pemeriksaan dasar ini dipakai untuk memisahkan pasien berisiko diabetes dari yang tidak**, memakai model klasifikasi linear yang sederhana?

Tujuan analisis.

1. Merumuskan kasus ini sebagai *supervised learning* dua kelas (klasifikasi biner), melanjutkan hasil analisis pada Tugas 1.
2. Mengimplementasikan **Perceptron** dan **ADALINE** secara mandiri memakai NumPy, serta menjelaskan bagaimana keduanya memakai sinyal error yang berbeda untuk memperbarui bobot.
3. Menjalankan rancangan eksperimen yang terkontrol (learning rate, jumlah epoch, standardisasi) dan mengevaluasi hasil secara terukur, termasuk mengidentifikasi keterbatasannya.

Perlu ditegaskan di awal: tujuan tugas ini **bukan** mengejar akurasi setinggi mungkin, melainkan menunjukkan prosedur implementasi yang benar, eksperimen yang dapat diulang, dan analisis yang didukung bukti numerik — sebagaimana ditekankan pada panduan tugas.

2. Dataset serta Kaitannya dengan Tugas 1

Dataset yang dipakai pada Tugas Besar 1 ini **sama** dengan yang dianalisis pada Tugas 1: *Pima Indians Diabetes Dataset*, disertakan sebagai `dataset.csv` pada repository ini. Dataset ini berisi hasil pemeriksaan medis dasar pada pasien perempuan, dengan label diagnosis diabetes yang sudah tersedia — pada Tugas 1, karakteristik ini (pasangan lengkap fitur `x` dan label `Outcome`) menjadi dasar kesimpulan bahwa kasus ini adalah **supervised learning (classification)**, bukan *clustering*. Tugas Besar 1 melanjutkan kesimpulan itu dengan mengimplementasikan model klasifikasi linear yang konkret.

Ukuran dan struktur. Dataset berisi **768 observasi** dan **9 kolom** (8 fitur + 1 target), seluruhnya bertipe numerik sehingga tidak diperlukan konversi kategori. Tidak ditemukan nilai `NaN`/*missing* maupun baris duplikat. Perlu dicatat: pada versi asli *Pima Indians Diabetes Dataset*, nilai `0` pada kolom `Glucose`, `BloodPressure`, `SkinThickness`, `Insulin`, dan `BMI` sesungguhnya merepresentasikan nilai yang hilang (secara fisiologis mustahil bernilai nol). Berkas `dataset.csv` yang dipakai di sini **tidak memiliki nilai nol** pada kolom-kolom tersebut, sehingga diperlakukan sebagai data yang sudah melalui praproses/imputasi sebelum dibagikan.

Fitur (x) dan target (y):

Kolom	Makna
`Pregnancies`	Jumlah kehamilan
`Glucose`	Kadar glukosa plasma
`BloodPressure`	Tekanan darah diastolik (mm Hg)
`SkinThickness`	Ketebalan lipatan kulit triceps (mm)
`Insulin`	Kadar insulin serum 2 jam (mu U/ml)
`BMI`	Indeks massa tubuh
`DiabetesPedigreeFunction`	Skor riwayat diabetes dalam keluarga
`Age`	Usia pasien (tahun)
`Outcome` (**target**)	`1` = diabetes (kelas positif), `0` = tidak diabetes

Distribusi kelas. Dari 768 sampel: **500 (65,1%) tidak diabetes** dan **268 (34,9%) diabetes** — kelas tidak seimbang, sehingga precision/recall/F1 dilaporkan pula pada Bagian 6, tidak hanya akurasi.

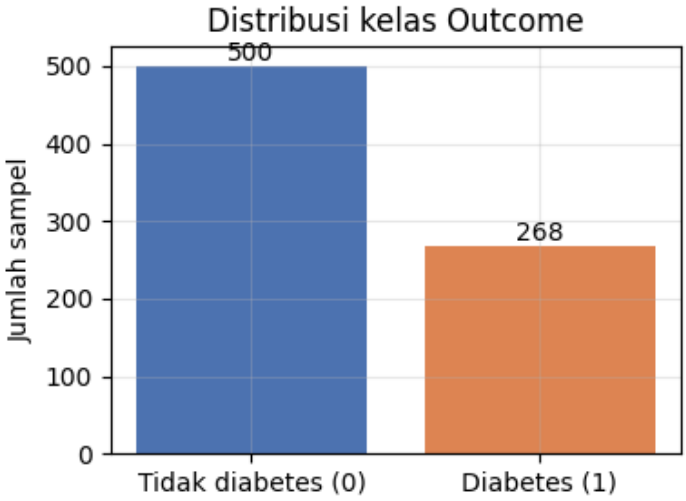


Figure 1: Distribusi kelas Outcome

Dua kelas yang dipakai. Dataset ini sudah biner (`Outcome` $\in \{0, 1\}$), sehingga tidak diperlukan pemilihan subset kelas — kedua kelas yang tersedia langsung dipakai, dengan `Outcome=1` (diabetes) sebagai **kelas positif**.

3. Artikel dan Kode Pendukung

Dua sumber utama dipakai sebagai rujukan teknis implementasi, keduanya tercantum pula pada panduan tugas:

1. **Rosenblatt, F. (1958).** *The perceptron: A probabilistic model for information storage and organization in the brain*. Psychological Review, 65(6), 386–408. https://doi.org/10.1037/h0042519 Sumber definisi Perceptron dan aturan pembaruan bobot berbasis kesalahan klasifikasi. Aturan pembaruan `w ← w + η(d−y)x` pada notebook ini mengikuti formulasi dasar artikel ini, diadaptasi ke notasi label `+1/−1` sesuai Ketentuan Tugas Besar 1 (Bagian C butir 3 pada panduan).
2. **Widrow, B., & Hoff, M. E. (1960).** *Adaptive switching circuits.* IRE WESCON Convention Record, Part 4, 96–104. https://isl.stanford.edu/~widrow/papers/c1960adaptiveswitching.pdf Sumber Delta Rule / Least Mean Squares yang dipakai ADALINE. Error `e = d − z` dihitung dari *linear response* **sebelum** fungsi aktivasi, bukan dari output kelas — diadaptasi langsung menjadi fungsi `train_adaline` pada notebook.
3. **Raschka, S. (t.t.).** *Adaline: Adaptive Linear Neuron Classifier.* Dokumentasi mlxtend. https://rasbt.github.io/mlxtend/user_guide/classifier/Adaline/ (diakses 6 Oktober 2026). Dipakai sebagai referensi struktur kode (pemisahan fungsi `predict` dan `fit`, pencatatan riwayat *cost* per epoch). Tidak ada baris kode yang disalin langsung dari dokumentasi ini — implementasi ditulis ulang dari nol memakai NumPy murni, memakai notasi `w, b` sesuai panduan tugas (bukan notasi `theta` *augmented* seperti pada materi kuliah Pertemuan 4–5).

Fungsi pelatihan Perceptron/ADALINE siap pakai (mis. dari scikit-learn) **tidak dipakai** sebagai model utama. scikit-learn hanya dipakai untuk `train_test_split` dan metrik evaluasi (`confusion_matrix`, `precision_score`, `recall_score`, `f1_score`), sesuai yang diizinkan panduan tugas.

4. Model Neuron dan Aturan Pembelajaran

Kedua model memakai neuron linear yang sama sebagai dasar:

$$z = w^\top x + b, \qquad \hat{y} = \begin{cases} +1 & \text{jika } z \geq 0 \\ -1 & \text{jika } z < 0 \end{cases}$$

Perbedaan Perceptron dan ADALINE terletak pada **sinyal error yang dipakai untuk memperbarui parameter**, bukan pada bentuk neuron itu sendiri.

Perceptron — koreksi dari hasil klasifikasi (*online*, per sampel). Untuk setiap sampel (x, y):

$$\Delta = \eta(y - \hat{y}), \qquad w \leftarrow w + \Delta x, \qquad b \leftarrow b + \Delta$$

Karena $\hat{y} \in \{-1, +1\}$, error hanya bernilai $\{-2, 0, +2\}$ — update terjadi hanya saat prediksi salah. Jumlah pembaruan (misklasifikasi) per epoch dicatat sebagai indikator training.

ADALINE — koreksi dari *linear response* kontinu (Delta Rule, *batch*). Memakai keluaran linear z (sebelum threshold):

$$e = y - z, \qquad w \leftarrow w + \eta \frac{X^\top e}{n}, \qquad b \leftarrow b + \eta \cdot \text{mean}(e)$$

Fungsi aktivasi/threshold **hanya dipakai saat prediksi**, tidak dipakai dalam perhitungan error training.

Fungsi objektif ADALINE:

$$J = \frac{1}{2n} \sum_i (y_i - z_i)^2, \qquad \text{MSE} = \frac{1}{n} \sum_i (y_i - z_i)^2 = 2J$$

Pada implementasi ini, J dan MSE **dicatat setelah pembaruan bobot pada epoch yang sama** (dihitung ulang memakai parameter terbaru) — hal ini dinyatakan eksplisit karena memengaruhi pembacaan kurva konvergensi pada Bagian 6.

Inisialisasi dan urutan data. Kedua model diinisialisasi dengan $w = \mathbf{0}$, $b = 0$. Urutan sampel data latih **tidak diacak ulang** tiap epoch (urutan tetap), agar efek murni dari η dan standardisasi dapat dibandingkan tanpa tercampur efek pengacakan.

Perhitungan Manual (Dua Langkah Pembaruan)

Perhitungan manual dijalankan memakai dua sampel pertama data latih yang sudah distandardisasi (Perceptron, $\eta = 0,1$) dan empat sampel pertama (ADALINE, dua iterasi batch, $\eta = 0,1$); kode lengkapnya ada pada `TB1_KelompokXX.ipynb`, bagian "Perhitungan Manual". Ringkasan hasilnya:

Perceptron — mulai dari $w = \mathbf{0}, b = 0$:

Langkah	z	$\hat{y}$	d	$\Delta = \eta(d - \hat{y})$	Update?
1	0,0000	+1	−1	0,1×(−1−1) = **−0,2**	Ya (salah)
2	−0,4170	−1	−1	0,1×(−1−(−1)) = **0**	Tidak (sudah benar)

Bobot (3 fitur pertama) setelah langkah 1: $w \approx [0{,}170,\ 0{,}211,\ 0{,}165]$, $b = -0{,}2$; tidak berubah lagi pada langkah 2.

ADALINE (batch, 4 sampel, $\eta = 0,1$) — mulai dari $w = \mathbf{0}, b = 0$:

Iterasi	e rata-rata	MSE sebelum update	b sesudah update
1	−1,000 (keempat sampel $z = 0$)	1,0000	−0,1000

Iterasi	e rata-rata	MSE sebelum update	b sesudah update
2	−0,715	0,5211	−0,1716

MSE menurun dari 1,0000 menjadi 0,5211 hanya dalam dua iterasi — konsisten dengan arah gradien yang menurunkan *squared error*, sesuai teori Delta Rule pada Bagian 4.

5. Penyiapan Data dan Rancangan Eksperimen

Pembagian data. Data dibagi **80% latih / 20% uji** dengan **stratifikasi kelas** dan `random_state=42` (dicatat agar hasil dapat diulang): 614 sampel latih (34,85% kelas positif) dan 154 sampel uji (35,06% kelas positif) — proporsi kelas terjaga hampir identik pada kedua bagian. Pembagian yang sama dipakai untuk kedua model pada seluruh konfigurasi.

Standardisasi. Parameter standardisasi (μ, σ per fitur) **hanya dipelajari dari data latih**, lalu diterapkan ke data latih maupun data uji — mencegah kebocoran informasi dari data uji ke proses pelatihan.

Label. `Outcome=1` (diabetes) → kelas positif `+1`; `Outcome=0` → `-1`, sesuai ketentuan tugas.

Delapan pelatihan. Enam konfigurasi utama (Perceptron dan ADALINE, masing-masing $\eta \in \{0,001;\ 0,01;\ 0,1\}$, 50 epoch, data terstandardisasi) ditambah satu eksperimen **tanpa standardisasi** per model ($\eta = 0,01$, 50 epoch) — total delapan pelatihan. Seluruh konfigurasi **ditentukan terlebih dahulu**; data uji baru dipakai sesudah pelatihan selesai untuk pelaporan akhir setiap konfigurasi, bukan untuk mencoba-coba parameter.

6. Hasil

6.1 Tabel seluruh konfigurasi

Model	η	Epoch	Standardisasi	Akurasi latih	Akurasi uji	Error/Loss akhir
Perceptron	0,001	50	Ya	0,6889	0,7013	176 (misklasifikasi)
ADALINE	0,001	50	Ya	0,7915	0,7338	0,9250 (MSE)
Perceptron	0,01	50	Ya	0,6889	0,7013	176 (misklasifikasi)
ADALINE	0,01	50	Ya	0,7932	0,7532	0,6553 (MSE)
Perceptron	0,1	50	Ya	0,6889	0,7013	176 (misklasifikasi)
ADALINE	0,1	50	Ya	0,7997	0,7273	0,5800 (MSE)
Perceptron	0,01	50	Tidak	0,6612	0,6299	213 (misklasifikasi)
ADALINE	0,01	**3** (berhenti awal)	Tidak	0,6515	0,6494	$1{,}80\times10^{14}$ (MSE)

Baris terakhir (ADALINE tanpa standardisasi) berhenti pada epoch ke-3 karena MSE menjadi tidak terhingga — bukan kegagalan kode, melainkan perilaku yang memang diharapkan ketika

gradient descent dijalankan pada fitur dengan skala yang jauh berbeda tanpa standardisasi (lihat Bagian 7c).

6.2 Confusion matrix, precision, recall, F1-score

Dipilih konfigurasi representatif per model ($\eta = 0{,}01$, data terstandardisasi) untuk dilaporkan metrik lengkapnya pada data uji ($n = 154$).

Perceptron ($\eta = 0{,}01$, standardisasi):

	Prediksi −1	Prediksi +1
Aktual −1 (tidak diabetes)	78	22
Aktual +1 (diabetes)	24	30

Akurasi = 0,7013 · Precision = 0,5769 · Recall = 0,5556 · F1 = 0,5660

ADALINE ($\eta = 0{,}01$, standardisasi):

	Prediksi −1	Prediksi +1
Aktual −1 (tidak diabetes)	78	22
Aktual +1 (diabetes)	16	38

Akurasi = 0,7532 · Precision = 0,6333 · Recall = 0,7037 · F1 = 0,6667

Pada konfigurasi ini, ADALINE mendeteksi lebih banyak kasus diabetes yang benar (*recall* lebih tinggi, 38 vs 30 dari 54 kasus positif) dibanding Perceptron, sejalan dengan akurasi ujinya yang juga lebih tinggi.

6.3 Kurva pelatihan

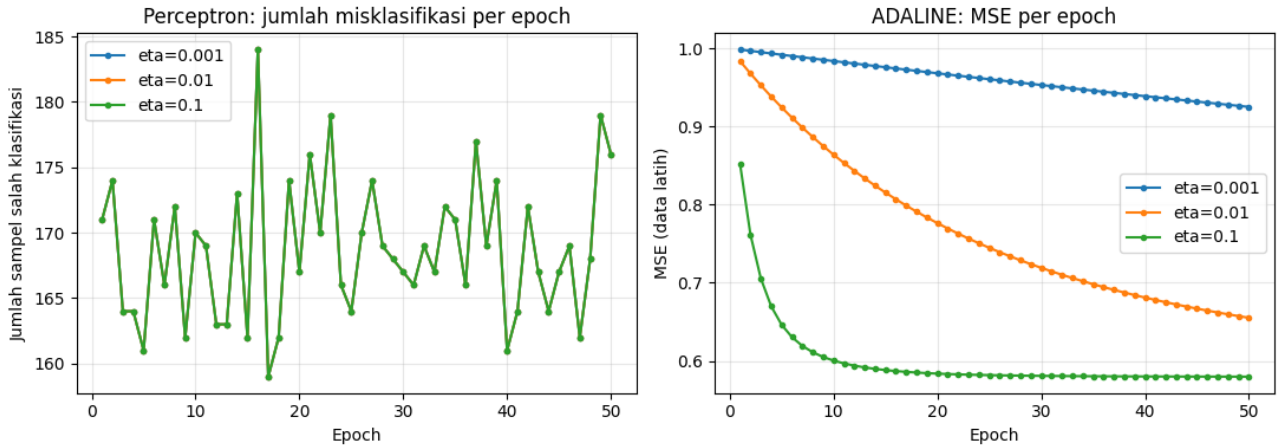


Figure 2: Perceptron: jumlah misklasifikasi per epoch (kiri) · ADALINE: MSE per epoch (kanan), tiga nilai η, data terstandardisasi

Ketiga kurva Perceptron pada panel kiri **saling bertumpuk sempurna** — konsekuensi langsung dari sifat invarian-skala yang dibahas pada Bagian 7c. Panel kanan menunjukkan ADALINE dengan η lebih besar menurunkan MSE lebih cepat pada 50 epoch pertama.

6.4 Perbandingan epoch ke-10, ke-30, dan ke-50

Tabel lengkap nilai pada ketiga titik epoch ada pada **Lampiran C**. Ringkasnya: jumlah misklasifikasi Perceptron **berosilasi**, bukan menurun monoton (mis. $\eta = 0{,}01$: 170 → 167 → 176) — wajar untuk data yang tidak linearly separable, karena tidak pernah tercapai kondisi nol-kesalahan

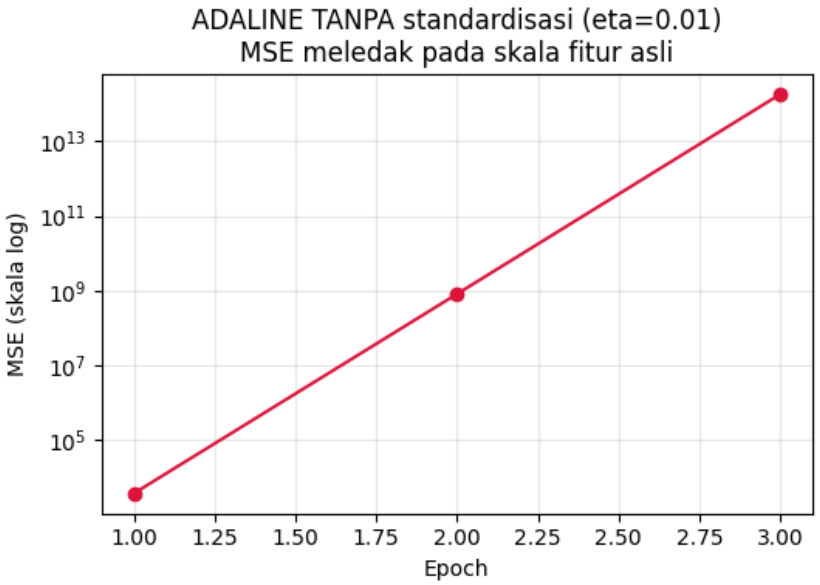


Figure 3: ADALINE tanpa standardisasi (η=0,01): MSE meledak secara eksponensial (skala log) dan pelatihan dihentikan pada epoch ke-3

yang membuat training berhenti secara alami. ADALINE dengan $\eta = 0{,}1$ sudah hampir stabil pada epoch ke-30 (MSE 0,601 → 0,581 → 0,580, penurunan melambat drastis), sedangkan $\eta = 0{,}001$ masih menurun perlahan hingga epoch ke-50 (0,984 → 0,953 → 0,925). ADALINE tanpa standardisasi sudah berhenti sejak epoch ke-3 karena MSE meledak.

6.5 Bobot dan bias akhir

Tabel lengkap bobot (w) dan bias (b) akhir untuk seluruh delapan konfigurasi dilampirkan pada **Lampiran A** (urutan fitur: `Pregnancies, Glucose, BloodPressure, SkinThickness, Insulin, BMI, DiabetesPedigreeFunction, Age`). Dua temuan utamanya:

Pola yang konsisten dan dapat diverifikasi secara eksak: bobot Perceptron pada $\eta = 0{,}01$ adalah **tepat 10×** bobot pada $\eta = 0{,}001$, dan bobot pada $\eta = 0{,}1$ adalah **tepat 100×** bobot pada $\eta = 0{,}001$ (diverifikasi untuk seluruh 8 fitur, bukan sampel sebagian). Bobot ADALINE **tidak** mengikuti pola penskalaan sesederhana ini antar η, karena arah pembaruannya ditentukan oleh gradien kontinu yang terus berubah seiring iterasi, bukan hanya oleh tanda kesalahan.

Bobot ADALINE tanpa standardisasi bernilai hingga puluhan ribu — bukti numerik langsung dari ledakan MSE yang dibahas pada Bagian 7c.

6.6 Decision boundary (visualisasi dua fitur)

Dataset utama memiliki 8 fitur sehingga *decision boundary* tidak dapat digambar langsung dalam bidang 2D. Sebagai **ilustrasi tambahan** (bukan bagian dari delapan konfigurasi utama), dilatih ulang Perceptron dan ADALINE memakai dua fitur paling berkorelasi dengan `Outcome` — **Glucose** (korelasi 0,496) dan **BMI** (korelasi 0,316) — agar batas keputusan dapat divisualisasikan. Model dua-fitur ini **hanya untuk visualisasi** (akurasi uji masing-masing 0,669 dan 0,708, lebih rendah dari model 8 fitur karena informasi yang dipakai lebih sedikit), bukan model yang dipakai untuk evaluasi akhir pada Bagian 6.1–6.5.

Sebaran titik pada kedua panel menunjukkan **tumpang tindih (overlap)** yang nyata antara dua kelas, bukan dua gerombolan terpisah bersih — petunjuk awal bahwa data secara umum tidak *linearly separable*, konsisten dengan temuan pada Bagian 7a yang memakai bukti dari seluruh 8 fitur.

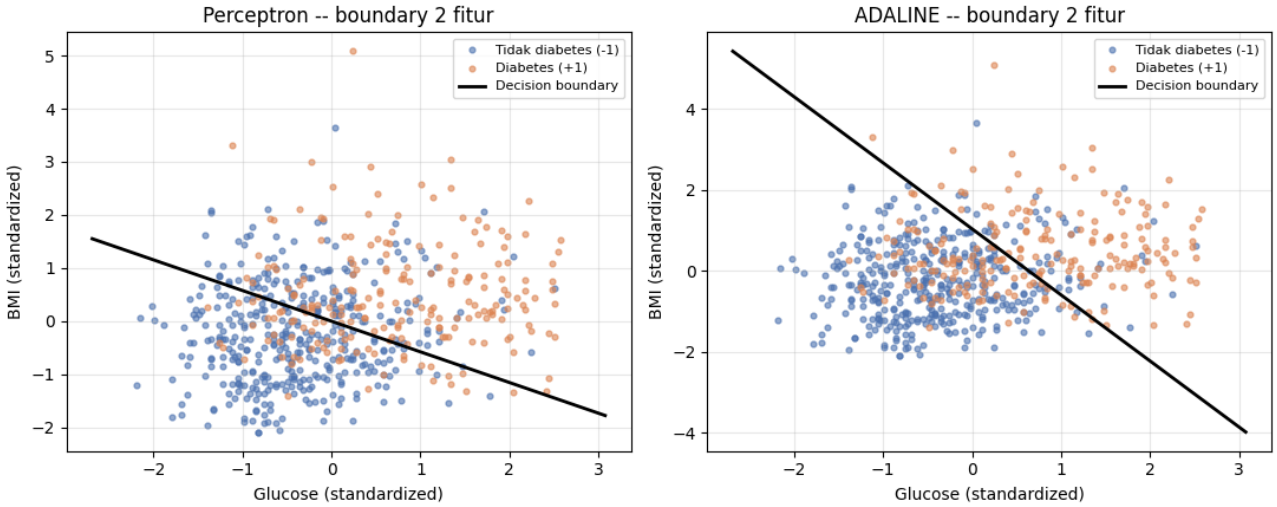


Figure 4: Decision boundary dua fitur (Glucose, BMI, terstandardisasi) — Perceptron (kiri) dan ADALINE (kanan)

7. Pembahasan dan Keterbatasan

a) Apakah data menunjukkan indikasi dapat dipisahkan secara linear?

Tidak. Perceptron pada seluruh nilai η (data terstandardisasi) berhenti pada **176 misklasifikasi** dari 614 data latih setiap kali, dan tidak pernah mencapai nol kesalahan hingga epoch ke-50 (Bagian 6.3–6.4). Padahal, bila data *linearly separable*, *Convergence Theorem* menjamin Perceptron akan berhenti pada nol kesalahan dalam jumlah update yang terbatas. Karena hal itu tidak terjadi — ditambah proyeksi dua fitur pada Bagian 6.6 yang menunjukkan dua kelas saling tumpang tindih — data ini **tidak terindikasi dapat dipisahkan secara linear sempurna** pada ruang fitur yang dipakai.

b) Bagaimana Perceptron dan ADALINE menggunakan error yang berbeda untuk memperbarui bobot?

Perceptron memakai error dari **hasil klasifikasi diskret** ($d - \hat{y} \in \{-2, 0, +2\}$): selama tanda z sudah menghasilkan kelas yang benar, tidak ada pembaruan sama sekali, walau z masih jauh dari target. ADALINE memakai error dari **linear response kontinu** ($d - z$, bernilai riil): bobot tetap diperbarui walau kelas prediksinya sudah benar, selama z belum persis sama dengan target. Konsekuensinya terlihat jelas pada hasil: akurasi latih Perceptron **identik** (0,6889) di ketiga nilai η, sedangkan akurasi latih ADALINE **berbeda** antar η (0,7915 / 0,7932 / 0,7997) karena arah dan besar gradiennya terus menyesuaikan diri terhadap jarak linear, bukan hanya benar/salah.

c) Bagaimana η, jumlah epoch, dan standardisasi memengaruhi pelatihan?

Pada Perceptron dengan inisialisasi $w = 0$ dan urutan data tetap, mengubah η **tidak mengubah akurasi maupun jumlah misklasifikasi sama sekali** — hanya menskalakan besar bobot akhir secara proporsional (diverifikasi: bobot pada $\eta = 0{,}01$ persis 10× bobot pada $\eta = 0{,}001$, dan $\eta = 0{,}1$ persis 100×; lihat Bagian 6.5). Ini konsisten dengan catatan analisis pada panduan tugas: karena fungsi keputusan hanya bergantung pada *tanda* z, penskalaan η yang konstan dan positif tidak mengubah urutan prediksi benar/salah pada data yang sama. Pada ADALINE, η yang berbeda **memang mengubah** titik berhenti kurva MSE setelah 50 epoch (0,925 / 0,655 / 0,580 untuk $\eta = 0{,}001/0{,}01/0{,}1$), karena gradient descent pada fungsi kuadratik sensitif terhadap besar langkah pembaruan.

Standardisasi berpengaruh besar, terutama pada ADALINE: tanpa standardisasi ($\eta = 0{,}01$), **MSE meledak** dari sekitar 1 menjadi $1{,}8 \times 10^{14}$ hanya dalam 3 epoch (Bagian 6.3), karena fitur

seperti `Insulin` dan `BMI` (skala puluhan) memiliki rentang nilai jauh berbeda dengan `DiabetesPedigreeFunction` (skala < 3) — gradien pada fitur berskala besar menjadi dominan, membuat pembaruan bobot terlalu agresif dan tidak stabil (*divergen*). Perceptron tanpa standardisasi tidak meledak (update dibatasi oleh tanda error, bukan besar error), tetapi akurasi ujinya tetap turun dari 0,7013 menjadi 0,6299, karena kontribusi tiap fitur terhadap z menjadi tidak seimbang.

d) Apakah akurasi yang sama menunjukkan proses pembelajaran yang sama? Apa keterbatasan hasil dan langkah pengembangan berikutnya?

Tidak. Tiga konfigurasi Perceptron pada poin (c) memiliki akurasi yang identik, tetapi **skala bobot akhirnya berbeda 10× dan 100×** — menunjukkan bahwa angka akurasi akhir saja tidak cukup untuk menyimpulkan proses belajarnya sama; riwayat pelatihan dan bobot tetap perlu diperiksa. Keterbatasan utama hasil tugas ini:

1. Perceptron dan ADALINE adalah *classifier* **linear**, sehingga performanya dibatasi oleh seberapa linear hubungan sesungguhnya antara fitur dan `Outcome` — akurasi uji di kisaran 0,63–0,75 mencerminkan batas kemampuan model linear pada data ini, bukan kegagalan implementasi.
2. Kelas pada dataset ini **tidak seimbang** (≈35% positif), sehingga akurasi semata dapat menyesatkan; metrik precision/recall pada Bagian 6.2 lebih informatif, dan menunjukkan recall Perceptron (0,56) cukup rendah untuk konteks medis (berarti banyak kasus diabetes yang tidak terdeteksi).
3. Evaluasi hanya memakai **satu** pembagian data latih/uji (bukan *cross-validation*), sehingga hasil dapat sedikit bervariasi pada pembagian lain.

Pengembangan berikutnya yang wajar: mencoba **MLP** dengan *hidden layer* dan fungsi aktivasi non-linear (sesuai arah materi Pertemuan 6 dan seterusnya pada mata kuliah ini) untuk menangkap pola non-linear yang tidak dapat dipisahkan oleh satu neuron linear, serta menambahkan *cross-validation* dan penanganan ketidakseimbangan kelas (mis. *class weighting*) pada iterasi berikutnya.

8. Kesimpulan

Kasus prediksi risiko diabetes pada dataset ini berhasil dirumuskan dan diuji sebagai *supervised learning* dua kelas memakai Perceptron dan ADALINE yang diimplementasikan dari nol memakai NumPy. Kedua model mencapai akurasi uji pada kisaran 0,63–0,75 — jauh dari sempurna, tetapi hal ini **konsisten** dengan temuan bahwa data tidak *linearly separable* (dibuktikan lewat jumlah misklasifikasi Perceptron yang tidak pernah nol, serta proyeksi 2D yang menunjukkan kelas saling tumpang tindih), bukan indikasi kesalahan implementasi — perhitungan manual pada Bagian 4 juga cocok persis dengan hasil kode pada notebook. ADALINE lebih responsif terhadap perubahan η karena memakai error kontinu, sementara Perceptron menunjukkan sifat invarian-skala terhadap η (hanya menskalakan bobot, tidak mengubah prediksi) yang konsisten dengan teori di balik aturan pembaruan berbasis tanda. Standardisasi fitur terbukti krusial, khususnya untuk ADALINE, sebagaimana ditunjukkan oleh MSE yang meledak hingga 10^{14} pada eksperimen tanpa standardisasi. Akurasi 100% memang bukan target tugas ini; yang lebih penting — dan telah ditunjukkan konsisten pada notebook dan laporan ini — adalah ketepatan prosedur eksperimen serta keselarasan antara perhitungan manual, kode, dan hasil yang dilaporkan.

9. Daftar Pustaka

Rosenblatt, F. (1958). The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review, 65*(6), 386–408. https://doi.org/10.1037/h0042519

Widrow, B., & Hoff, M. E. (1960). Adaptive switching circuits. *IRE WESCON Convention Record*, Part 4, 96–104. https://isl.stanford.edu/~widrow/papers/c1960adaptiveswitching.pdf

Raschka, S. (t.t.). Adaline: Adaptive Linear Neuron Classifier. mlxtend documentation. https://rasbt.github.io/mlxtend/user_guide/classifier/Adaline/ (diakses 6 Oktober 2026)

Da Silva, I. N., Spatti, D. H., Flauzino, R. A., Liboni, L. H. B., & dos Reis Alves, S. F. (2017). *Artificial Neural Networks: A Practical Course.* Springer.

Haykin, S. (2009). *Neural Networks and Learning Machines* (3rd ed.). Pearson.

Materi kuliah Jaringan Syaraf Tiruan (IT6053) Pertemuan 1–5, Matahari Bhakti Nendya, S.Kom., M.T., FTI UKDW (2026).

Lampiran A — Tabel Lengkap Bobot dan Bias Akhir

Urutan fitur: `Pregnancies, Glucose, BloodPressure, SkinThickness, Insulin, BMI, DiabetesPedigreeFunction, Age`. Dirujuk dari Bagian 6.5.

Model	η	Std	bias b	bobot w (8 fitur, urutan di atas)
Perceptron	0,001	Ya	−0,0040	0,005, −0,000, 0,001, −0,001, 0,005, 0,004, −0,004, −0,003
Perceptron	0,01	Ya	−0,0400	0,052, −0,004, 0,012, −0,007, 0,047, 0,035, −0,039, −0,031
Perceptron	0,1	Ya	−0,4000	0,522, −0,044, 0,119, −0,066, 0,471, 0,350, −0,386, −0,309
ADALINE	0,001	Ya	−0,0148	0,009, 0,023, 0,008, 0,014, 0,019, 0,015, 0,007, 0,011
ADALINE	0,01	Ya	−0,1197	0,058, 0,157, 0,042, 0,079, 0,121, 0,091, 0,045, 0,060
ADALINE	0,1	Ya	−0,3014	0,106, 0,317, 0,009, 0,068, 0,157, 0,147, 0,054, 0,041
Perceptron	0,01	Tidak	−15,74	14,04, −1,40, −22,98, 2,28, 4,84, 5,39, 2,58, −2,66
ADALINE	0,01	Tidak	−270,16	−1075,9, −34824,6, −19735,6, −8109,5, −44692,0, −8958,6, −135,3, −9281,1

Lampiran B — Perhitungan Manual Lengkap

Kode yang menghasilkan angka pada Bagian 4 (perhitungan manual) dapat dijalankan ulang pada `TB1_KelompokXX.ipynb`, bagian bertajuk "Perhitungan Manual (Dua Langkah Pembaruan)". Nilai antara (sebelum dibulatkan untuk tampilan) tersimpan pada keluaran sel tersebut, termasuk nilai x lengkap (8 fitur) untuk tiap sampel yang dipakai pada demonstrasi.

Lampiran C — Perbandingan Epoch ke-10, ke-30, dan ke-50

Dirujuk dari Bagian 6.4.

Model	η	Std	Epoch 10	Epoch 30	Epoch 50
Perceptron	0,001	Ya	170 err	167 err	176 err
Perceptron	0,01	Ya	170 err	167 err	176 err
Perceptron	0,1	Ya	170 err	167 err	176 err
Perceptron	0,01	Tidak	213 err	219 err	213 err
ADALINE	0,001	Ya	MSE 0,984	MSE 0,953	MSE 0,925
ADALINE	0,01	Ya	MSE 0,864	MSE 0,719	MSE 0,655
ADALINE	0,1	Ya	MSE 0,601	MSE 0,581	MSE 0,580
ADALINE	0,01	Tidak	berhenti (epoch 3)	berhenti	berhenti